





# **Tecnológico Nacional de México Instituto Tecnológico de Tijuana**

Subdirección Académica

Departamento de Sistemas y Computación

Semestre: Febrero - Julio 2021

Materia:

**Datos Masivos** 

**Profesor:** 

Jose Christian Romero Hhernandez

**Alumno:** 

Briseño Cota Raul Omar Aceves Zamora Juan Antonio

Fecha:

15 de Abril del 2021

# Evaluación 1

### Cuestionario

#### 1. Comienza una simple sesión Spark

Comenzamos importando librerías necesarias para construir la sesión y otras necesarias para el funcionamiento correcto de los siguientes incisos.

```
scala> import org.apache.spark.sql.SparkSession
import org.apache.spark.sql.functions._
scala> import org.apache.spark.sql.functions._
import org.apache.spark.sql.functions._
scala> import spark.implicits._
import spark.implicits._
scala> val spark = SparkSession.builder().getOrCreate()
spark: org.apache.spark.sql.SparkSession = org.apache.spark.sql.SparkSession@76929266
```

#### 2. Cargue el archivo Netflix Stock CSV, haga que Spark infiera los tipos de datos.

Con el siguiente código debemos saber la ubicación del archivo csv que necesitamos

```
scala> val NetDF = spark.read.option("header", "true").option("inferSchema", "true")csv("C:\\Users\\brise\\Documents\\GitHub\\DatosMasivos\\Eva
luation 1\\Netflix_2011_2016.csv")
NetDF: org.apache.spark.sql.DataFrame = [Date: timestamp, Open: double ... 5 more fields]
```

### 3. ¿Cuáles son los nombres de las columnas?

```
scala> val ColNames: Array[String] = NetDF.columns
ColNames: Array[String] = Array(Date, Open, High, Low, Close, Volume, Adj Close)
scala> ColNames.foreach(name => println(s"$name"))
Date
Open
High
Low
Close
Volume
Adj Close
```

#### 4. ¿Cómo es el esquema?

```
scala> NetDF.printSchema()
root
|-- Date: timestamp (nullable = true)
|-- Open: double (nullable = true)
|-- High: double (nullable = true)
|-- Low: double (nullable = true)
|-- Close: double (nullable = true)
|-- Volume: integer (nullable = true)
|-- Adj Close: double (nullable = true)
```

5. Imprime las primeras 5 columnas

```
scala> NetDF.columns.take(5)
res2: Array[String] = Array(Date, Open, High, Low, Close)
```

6. Usa describe() para aprender sobre el DataFrame

count   1259   1					v()	tDF.describe().show	scala> Ne
mean 230.39351086656092 233.97320872915006 226.80127876251044 230.522453845909 2.5634836060365368E7	Adj Close	Volume	Close	Low	High	Open	summary
min  53.990001  55.480001  52.81  53.8  3531300	55.610540036536875   35.186669331525486    7.685714	2.306312683388607E7 3531300	230.522453845909 164.40918905512854 53.8	226.80127876251044 162.6506358235739 52.81	233.97320872915006 165.9705082667129 55.480001	230.39351086656092 164.37456353264244 53.990001	mean   stddev   min

7. Crea un nuevo dataframe con una columna nueva llamada "HV Ratio" que es la relación entre el precio de la columna "High" frente a la columna "Volume" de acciones negociadas por un día. (Hint: Es una operación de columnas).

```
val NetDF2 = NetDF.withColumn("HV Ratio",NetDF("High")/NetDF("Volume"))
: org.apache.spark.sql.DataFrame = [Date: timestamp, Open: double ... 6 more fields]
NetDF2: org.apache.spark.sql.DataFrame
scala> NetDF2.show()
                                                                                                                                          Adj Close
                                                                    High
                                                                                                         Close | Volume
                                    119.100002 | 120.28000300000001 | 115.100004 |
                                                                                                   118.839996 | 120460200 |
                                                                                                                                          16.977142|9.985040951285156E-7
2011-10-24 00:00:00
                                                                                                    77.370002 315541800 11.052857000000001 2.515989989281927E-7
79.400002 148733900 11.342857 5.474206014903126E-7
2000000001 71190000 11.55142899999999 1.161960907430818...
                                     74.899999
                                                               79.390001 74.249997
2011-10-25 00:00:00
                                                             2011-10-26 00:00:00
                                         78.73
2011-10-27 00:00:00
                                     82.179998
                                                   82.71999699999999
2011-10-28 00:00:00 80.280002
2011-10-31 00:00:00 83.63999799999999
                                                                                                                 57769600
                                                                                                                                          12.02 1.465476686700271.
11.725715 2.120614572195210.
                                                              84.660002|
                                                                            79.599999 | 84.140003000000001 |
                                                              84.090002 81.450002
                                                                                                    82.080003
                                                                                                                  39653600
                                                              80.999998 78.74
84.40002 80.109998
2011-11-01 00:00:00
                                                                                                    80.089997
                                                                                                                   33016200
                                                                                                                                           11.441428 2.453341026526372E
2011-11-02 00:00:00
                                                                                                                  41384000
                                                                                                                                          11.912857 2.039435578967717E-6
                                     80.709998
                                                                                                    83.389999
2011-11-03 00:00:00
                                                              92.600003
                                                                                                    92.290003
                                                                                                                   94685500 13.184285999999998 9.77974483949496E
                                                                                                                                          12.86|1.099502069629999.
12.975715|1.976194645910725.
2011-11-04 00:00:00 91.46999699999999
2011-11-07 00:00:00 91.0
                                                   92.89000300000001 87.749999
93.839998 89.979997
                                                                                                    90.019998
90.830003
                                                                                                                  84483700
                                                                                                                  47485200
2011-11-08 00:00:00 91.2299989999999
                                                              92.600003
                                                                            89.650002
                                                                                                    90.470001
                                                                                                                   31906000
                                                                                                                                          12.578571 | 3.145082800111281E-6
12.16 | 2.279474054889131E-6
                                                              90.440001 87.999998
2011-11-09 00:00:00
                                     89.000001
                                                                                                    88.049999
                                                                                                                  28756000
                                                                            84.839999 85.11999899999999
                                                                                                                                          12.535714|2.305965805108520..
12.245714|4.039190694731629..
| 2011-11-11 | 00:00:00
| 2011-11-14 | 00:00:00
                                     85.899997
                                                              87.949997
                                                                                                                  38140200
                                                                                 85.45
                                     87.989998
                                                                   88.1
                                                                                                    85.719999
                                                                                                                  21811300
                                                              87.050003 | 84.499998
86.460003 | 80.890002
80.999998 | 75.789999
                                                                                                                  21372400 | 12.325714 | 4.073010190713256...
34560400 | 11.59714299999999 | 2.501707242971725E-6
2011-11-15 00:00:00
2011-11-16 00:00:00
                                                                                                    86.279999
                                                                                                    81.180002
                                     86.460003
2011-11-18 00:00:00
                                                              78.999999 76.039998
                                                                                                    78.0599981
                                                                                                                 34729100
                                                                                                                                          11.151428 2.274749388841058.
only showing top 20 rows
```

8. ¿Qué día tuvo el pico mas alto en la columna "Close"?

9. Escribe con tus propias palabras en un comentario de tu código. ¿Cuál es el significado de la columna Cerrar "Close"?

Es el valor al finalizar el mes

10. ¿Cuál es el máximo y mínimo de la columna "Volume"?

```
scala> NetDF.select(max("Volume"), min("Volume")).show()
+-----+
|max(Volume)|min(Volume)|
+----+
| 315541800| 3531300|
+-----+
```

11. Con Sintaxis Scala/Spark \$ conteste los siguiente:

a. ¿Cuántos días fue la columna "Close" inferior a \$ 600?

```
scala> NetDF.filter($"Close"<600).count()
res7: Long = 1218</pre>
```

b. ¿Qué porcentaje del tiempo fue la columna "High" mayor que \$ 500?

```
scala> (NetDF.filter($"High" > 500).count() * 1.0/ NetDF.count())*100
res8: Double = 4.924543288324067
```

c. ¿Cuál es la correlación de Pearson entre columna "High" y la columna "Volumen"?

```
scala> NetDF.select(corr("High","Volume")).show()
+-----+
| corr(High, Volume)|
+-----+
|-0.20960233287942157|
+-----+
```

d. ¿Cuál es el máximo de la columna "High" por año?

e. ¿Cuál es el promedio de columna "Close" para cada mes del calendario?

```
scala> val monthdf = NetDF.withColumn("Month",month(NetDF("Date")))
monthdf: org.apache.spark.sql.DataFrame = [Date: timestamp, Open: double ... 6 more fields]
scala> val monthavgs = monthdf.select($"Month",$"Close").groupBy("Month").mean()
monthavgs: org.apache.spark.sql.DataFrame = [Month: int, avg(Month): double ... 1 more field]
scala> monthavgs.select($"Month",$"avg(Close)").orderBy("Month").show()
Month
              avg(Close)
    1 212.22613874257422
    2 254.1954634020619
    3 249.5825228971963
    4 246.97514271428562
    5 264.37037614150944
    6 295.1597153490566
     7 243.64747528037387
    8 | 195.25599892727263 |
    9 | 206 . 09598121568627 |
   10 | 205.93297300900903 |
   11 194.3172275445545
    12 | 199.3700942358491 |
```

## Código

```
//7. Create a new column called "HV Ratio" which is the relationship
// of the "High" column in front of the "Volume" column of shares traded
// Added the new column "HV Ratio" which will have the result of the
division of "High" by "Volume".
val NetDF2 = NetDF.withColumn("HV Ratio",NetDF("High")/NetDF("Volume"))
NetDF2.show()
//8.What day had the highest peak in the "close" column?
NetDF.groupBy(dayofweek(NetDF("Date")).alias("Day")).max("Close").sort(a
sc("Day")).show()
//9. What is the meaning of the Close column "Close"?
NetDF.select(max("Volume"), min("Volume")).show()
//11.With Scala / Spark $ syntax answer the following:
NetDF.filter($"Close"<600).count()</pre>
// b)What percentage of the time was the "High" column greater than $
(NetDF.filter($"High" > 500).count() * 1.0/ NetDF.count())*100
NetDF.select(corr("High","Volume")).show()
// d) What is the maximum in the "High" column per year?
"veardf"
val yeardf = NetDF.withColumn("Year",year(NetDF("Date")))
// The year and the maximum of "High" were selected from the variable
"yeardf", from the maximum to the minimum in the years.
val yearmaxs = yeardf.select($"Year",$"High").groupBy("Year").max()
val res = yearmaxs.select($"Year",$"max(High)")
res.orderBy("Year").show()
```

```
// e) What is the average of the "Close" column for each calendar month?
// The column "Month" of the data "Date" was added, in the variable
"monthdf".
val monthdf = NetDF.withColumn("Month",month(NetDF("Date")))
// The month and the average of "Close" were selected from the variable
"monthdf".
val monthavgs =
monthdf.select($"Month",$"Close").groupBy("Month").mean()
// The average of the "Close" column for each calendar month was
selected and displayed.
monthavgs.select($"Month",$"avg(Close)").orderBy("Month").show()
```

#### Conclusión:

Nuestra conclusión fue que estas herramientas en realidad si ayudan de una manera eficaz y eficiente a gestionar un "dataframe" ya que de manera específica se puede obtener el resultado que se desea saber sin necesidad de tanta fórmula y de una manera dinámica e inusual.